

Clasificación de Riesgo Clínico en Lesiones Cutáneas

Proyecto evaluación 2— Programación para la Ciencia de
Datos

Integrantes:

Benjamín Figueroa

Emmanuel Moreno

Daniel Vidal

Asignatura: Programación para la Ciencia de Datos.

Profesor: Oscar Oliva González

Sección: 002_V

Planteamiento del problema: triaje clínico bajo desbalance extremo

990

Casos alto riesgo (clase positiva)

10


Casos bajo riesgo (clase negativa)

Por qué importa (ingeniería + clínica)

- Objetivo: apoyar decisiones de triaje, priorizando la detección de casos de alto riesgo.
- El desbalance severo induce una falsa sensación de desempeño: una accuracy alta puede coexistir con fallos críticos.
- Requisito clave: priorizar Recall/F1 para la clase clínicamente relevante y controlar falsos negativos.




≈99% alto riesgo



≈1% bajo riesgo

Pipeline reproducible (Scikit-learn)



Justificación de ingeniería

- Pipelines: automatizan el flujo extremo-a-extremo y previenen data leakage (preprocesamiento dentro de CV).
- ColumnTransformer: escalado numérico consistente + codificación categórica robusta (handle_unknown='ignore').
- RandomForest: robusto ante relaciones no lineales; permite aprendizaje sensible al costo con class_weight='balanced'.

Preprocesamiento: ColumnTransformer + Pipeline

Decisiones clave de ingeniería

- Separación explícita de variables numéricas vs. categóricas.
- StandardScaler para numéricas (estandarización consistente).
- OneHotEncoder para categóricas (drop='first', handle_unknown='ignore').
- Todo dentro del Pipeline → evita data leakage durante validación.

Resultado esperado

Un flujo reproducible donde el mismo preprocesamiento se aplica en entrenamiento, prueba y validación cruzada, manteniendo consistencia y trazabilidad.

Implementación (Scikit-learn)

```
preprocessor = ColumnTransformer([
    ('num', StandardScaler(), cols_num),
    ('cat', OneHotEncoder(
        drop='first',
        handle_unknown='ignore'),
        cols_cat)
])

pipeline = Pipeline([
    ('preprocessor', preprocessor),
    ('clf', RandomForestClassifier(
        class_weight='balanced'))
])
```

Aprendizaje supervisado: Random Forest + manejo del desbalance

Por qué Random Forest

- Captura relaciones no lineales y efectos de interacción.
- Robusto ante ruido y escalamiento (aun así se estandariza por consistencia).
- Entrega señales de interpretabilidad (feature importance) útiles para CDSS.

Costo asimétrico (clínica)

Se configura `class_weight='balanced'` para penalizar errores según la frecuencia de clase y reducir el sesgo hacia la clase mayoritaria.

Aprendizaje sensible al costo

$w_c \propto 1 / n_c$ (pesos inversos a la frecuencia)

Objetivo: que el modelo “sienta” el costo del desbalance durante el entrenamiento.

Hiperparámetros a optimizar

- `n_estimators`
- `max_depth`
- `min_samples_split`
- `criterion` (gini/entropy)

Nota: tuning con CV usando `scoring='f1'`.

Configuración experimental: split estratificado 80/20

Protocolo entrenamiento/prueba

- `train_test_split(test_size=0.20, stratify=y, random_state=42)`
- Mantiene proporciones de clase en ambos subconjuntos
- Objetivo: evaluar generalización en condiciones realistas

Foco de evaluación

- Métricas sensibles al desbalance (Recall/F1)
- Confusion Matrix para interpretar riesgos clínicos
- CV para tuning con `scoring='f1'`

Dataset (N=1000)

Split estratificado

Entrenamiento (80%)


Fit + tuning (CV)

**Prueba
(20%)**



Evaluar → Matriz de Confusión / F1 / Recall

Por qué el aprendizaje no supervisado no fue suficiente



PCA (2D) para inspección estructural

Clustering con K-Means

- $n_clusters = 2$ (alto vs bajo)
- Métrica: Silhouette

Coeficiente Silhouette


0.1014

Interpretación

Solapamiento significativo: los clusters naturales no separan el diagnóstico clínico.

→ Se requiere aprendizaje supervisado.

Matriz de confusión (conjunto de prueba)



Patrón observado

- El modelo predice casi siempre “alto riesgo”.
- Una accuracy alta puede ocultar fallos en la clase minoritaria.
- En clínica, el costo del error es asimétrico.

Mensaje clave

Optimizar para minimizar FN en la clase crítica.

- Recall: sensibilidad
- F1: balance precisión/recall
- Accuracy: no es robusta con desbalance extremo

Estrategia de métricas bajo desbalance severo

Por qué falla la Accuracy aquí

Con ~99% de una clase, un modelo trivial puede lograr ~99% accuracy sin aprender nada útil.

En un escenario clínico, los errores relevantes se reflejan mejor en métricas de clase (Recall/F1) y en la matriz de confusión.

Reporte de clasificación (test)

Clase	Precision	Recall	F1	Support
Riesgo Bajo (0)	0.00	0.00	0.00	2
Riesgo Alto (1)	0.99	1.00	0.99	198
Accuracy		0.99		200

Implicación práctica

El desempeño en la clase minoritaria debe tratarse como un requisito de seguridad: ajustar el umbral de decisión, recolectar más casos de bajo riesgo, y reportar curvas Precision–Recall/ROC para una lectura robusta.

Estrategia de ajuste: GridSearchCV + RandomizedSearchCV

GridSearchCV (exhaustivo)

- Búsqueda sistemática en una malla discreta
- `cv=5, scoring='f1', n_jobs=-1`
- Útil cuando el espacio es acotado y se requiere trazabilidad

RandomizedSearchCV (estocástico)

- Explora combinaciones al azar (`n_iter`)
- Mayor cobertura con costo computacional fijo
- Recomendado cuando el espacio de búsqueda crece

Mejor resultado (GridSearchCV)

**F1 (CV) =
0.9950**

Mejores parámetros:

- `n_estimators: 100`
- `max_depth: None`
- `min_samples_split: 2`
- `criterion: gini`

Reflexión estratégica: explicabilidad y próximos pasos

Explicabilidad (requisito CDSS)

- Random Forest permite interpretabilidad relativa (feature importance), pero no reemplaza explicación clínica.
- Recomendado: SHAP/Permutation Importance + análisis de estabilidad.
- Auditoría: sesgos por variables demográficas y de exposición.

Recomendaciones futuras

- Re-balanceo: recolectar más muestras de bajo riesgo o usar técnicas focalizadas (SMOTE con cuidado).
- Ajuste de umbral según costo clínico (FN >> FP).
- Reporte completo: curva PR, calibración y sensibilidad por subgrupos.

Mentalidad de despliegue

Mantener el Pipeline como unidad de despliegue (preprocesamiento + modelo + validaciones). Versionamiento de datos y monitoreo para drift (población/estacionalidad).

Preguntas

Gracias.